# **Translation Methods**

Лабораторные:

- 1. perl
- 2. Ручное построение трансляторов
- 3. Использование автоматических генераторов трансляторов **e.g.** ANTLR (java), Bison + Yacc (c++), Happy (haskell)
- 4. Написание автоматического генератора транслятора
- 1 pcms, 2-4 защита

 $\Sigma, \Sigma^*, L \subset \Sigma^*$  - формальный язык

Базовый класс формальных языков - регулярные (= автоматные). Для порождения - регулярные выражния, для распозования - конечные автоматы

Контекстно-свободные языки: КС грамматики / МП автоматы

**токены (лексемы)** - единые неделимые элементы языка ( $\in \Sigma$ )

### Лексический анализ

Первый этап любого разбора - лексический анализ

Последовательность символов -> последовательность токенов ( $\in \Sigma^*$ )

e.g. арифмитические выражения

$$\Sigma = \{n, +, \times, (, )\}$$
 $(2 + 2) \times 2 \rightarrow (n + n) \times n$ 
 $n : (0|1|...|9)(0|1|...|9)^*$ 

жадный лексический анализ на базе регулярных выражений: пропускем пробельные символы, смотрим первый непробельный, находим максимальный префикс какого-то возможного токена

- 1. Проверить, что строка выводится в грамматике  $\Gamma$  // алгоритм КЯК  $\mathrm{O}(n^3)$
- 2. Построить дерево разбора
- 3. Синтаксически управляемая трансляция

$$egin{aligned} E 
ightarrow T \ E 
ightarrow E + T \ T 
ightarrow F \ T 
ightarrow T imes F \ F 
ightarrow n \ F 
ightarrow (E) \end{aligned}$$

**Аттрибуто транслирующие грамматики** - КСГ с добавлением двух элементов: аттрибуты и транслирующие символы

**транслирующие символы** - фрагменты кода, которые вставляем в грамматику, которые могут взаимодействовать с аттрибутами

$$E \to E + T \{E_0.v = E_1.v + T.v\}$$

```
T 
ightarrow T 	imes F \left\{ T_0.\, v = T_1.\, v \,+\, F.\, v 
ight\}
```

Нужно быстрее, чем за куб => накладываем ограничения на грамматики

**Однозначность** - если у любого слова не более одного дерева разбора в этой грамматике // Модификация алгоритма Эрли -  $\mathrm{O}(n^2)$ 

**LL, LR** - грамматики, на которые наложены дополнительные ограничения, чтобы разбор работал за линейное время

 $\Gamma$ , w на вход

Можем строить дерево разбора сверзу вниз - **нисходящая трансляция**. Шаг называется *раскрытие нетерминала* 

Снизу вверх - восходящий разбор. Шаг - свёртка

## Метод нисходящих трансляций для LL грамматик

s - стартовый нетерминал, w - слово, префикс которого разобран (x, y left)

**LL(k) - грамматика** - если достаточно посмотреть на первые k символов y, чтобы понять, какое правило применить для нетерминала A

Грамматика 
$$\Gamma$$
 называется **LL(1) грамматикой**, если  $s\Rightarrow^*xA\xi\Rightarrow x\alpha\xi\Rightarrow^*xc\eta$  
$$s\Rightarrow^*xA\tau\Rightarrow x\beta\sigma\Rightarrow^*xc\zeta$$
  $\alpha=\beta$ 

```
\begin{split} \operatorname{def} \mathit{FIRST} \colon (N \cup \Sigma)^* &\to 2^{\Sigma \cup \{\epsilon\}} \\ c \in \mathit{FIRST}(\alpha) \Leftrightarrow \alpha \Rightarrow^* \mathit{cx} \\ e \in \mathit{FIRST}(\alpha) \Leftrightarrow \alpha \Rightarrow^* \epsilon \\ \\ \mathbf{e.g.} \ S \to SS \\ S \to (S) \\ S \to \epsilon \\ \\ \mathit{FIRST}(S) = \{c, \epsilon\} \\ \\ \mathit{FIRST}('S)') = \{(,)\} \\ \\ \mathit{FIRST}(\epsilon) = \{\epsilon\} \\ \\ \mathit{FIRST}('))((') = \{')'\} \end{split}
```

# Алгортим удаления бесполезных символов

- 1. Удалить непорождающие символы
- 2. Удалить недостижимые

### Удаление непорождающих символов

1. Множество непорождающих символов  $Gen=\emptyset$  do {

for A 
$$ightarrow lpha$$

```
if lpha \in (\Sigma \cup Gen)^* : {\sf Gen} \ \cup = {\sf A} } while Gen change {\sf NonGen} = {\sf N} \setminus {\sf Gen}
```

```
1 A - порождающий, но Алгоритм 1 выбрал как порождающий
2
3 $A \Rightarrow \alpha \Rightarrow^{k - 1} x$
```

### Лемма о рекурсивном вычислении FIRST

```
\begin{split} &\alpha = c\beta \\ &FIRST(\alpha) = \{c\} \\ &\alpha = A\beta \\ &FIRST(\alpha) = (FIRST(A)) \setminus \epsilon) \cup (FIRST(\beta) \ if \ \epsilon \in FIRST(A)) \\ &FIRST(\epsilon) = \{\epsilon\} \end{split}
```

### Алгоритм

```
FIRST: map<N, set<\Sigma \cup \epsilon>> function getFIRST(\alpha)  \text{if } \alpha = \epsilon \text{ return } \{\epsilon\}   \text{if } \alpha[i] \in \Sigma \text{ return } \{\alpha[i]\}   \# \alpha[0] \in N   \text{return } (FIRST[\alpha[0]] \setminus \epsilon) \cup (getFIRST(\alpha[1:]), if \epsilon \in FIRST[\alpha[0]])
```

### Алгоритм построения FIRST

```
\begin{split} &\text{do } \{ \\ &\text{for A} \to \alpha \text{:} \\ &\text{FIRST[A]} \cup = getFIRST(\alpha) \\ \} \text{ while FIRST changes} \\ &\text{def } FOLLOW \text{: } N \to 2^{\Sigma \cup \{\$\}} \\ &c \in FOLLOW(A) \Leftrightarrow S \Rightarrow^* \alpha Ac\beta \\ &\$ \in FOLLOW(A) \Leftrightarrow S \Rightarrow^* \alpha A \end{split}
```

### Алгоритм FOLLOW

```
FOLLOW: map<N, set<\Sigma \cup \$>> FOLLOW(S) = \{\$\} do \{
```

```
\begin{array}{l} \text{for A} \to \alpha \\ \\ \text{for B in } \alpha \\ \\ \text{let } \alpha = \xi B \eta \\ \\ \text{FOLLOW(B)} = \text{FIRST}(\eta) \setminus \epsilon \\ \\ \text{if } \epsilon \in FIRST(\eta) \\ \\ \text{FOLLOW(B)} \ \cup = \text{FOLLOW(A)} \\ \} \text{ while FOLLOW changes} \end{array}
```

# Теорема

```
\Gamma является LL(1) \Leftrightarrow \forall A \to \alpha, A \to \beta:

1. FIRST(\alpha) \cap FIRST(\beta) = \emptyset
2. \epsilon \in FIRST(\alpha) \Rightarrow FIRST(\beta) \cap FOLLOW(A) = \emptyset

Доказательство:
\Rightarrow) от противного:
\exists He (1)

1. \exists A \to \alpha, A \to \beta, c \in FIRST(\alpha) \cap FIRST(\beta)

S \Rightarrow^* xA\sigma \Rightarrow x\alpha\sigma \Rightarrow^* xc\xi\sigma

S \Rightarrow^* xA\sigma \Rightarrow x\beta\sigma \Rightarrow^* xc\eta\sigma

2. \epsilon \in FIRST(\alpha) \cap FIRST(\beta)

S \Rightarrow^* xA\sigma \Rightarrow x\alpha\sigma \Rightarrow^* x\sigma \Rightarrow xc\tau

S \Rightarrow^* xA\sigma \Rightarrow x\beta\sigma \Rightarrow^* x\sigma \Rightarrow xc\tau

S \Rightarrow^* xA\sigma \Rightarrow x\beta\sigma \Rightarrow^* x\sigma \Rightarrow xc\tau
S \Rightarrow^* xA\sigma \Rightarrow x\beta\sigma \Rightarrow^* x\sigma \Rightarrow xc\tau
S \Rightarrow^* xA\sigma \Rightarrow x\beta\sigma \Rightarrow^* x\sigma \Rightarrow xc\tau
```

# Рекурсивный спуск

```
A\to\alpha_1|\alpha_2|\dots|\alpha_k Node: s{:}\ N\cup\Sigma ch{:}\ array(\mathsf{Node}) \mathsf{token}{:}\ \Sigma\cup\{\$\} \mathsf{next}() \mathit{FIRST'}(A\to\alpha)=(\mathit{FIRST}(\alpha)\setminus\epsilon)\cup(\mathit{FOLLOW}(A)\ if\ \epsilon\in\mathit{FIRST}(\alpha))
```

```
Node A() {
 2
        Node res = Node(A)
 3
        switch (token)
            FIRST'(A -> a1):
 4
 5
                // a1 = X1X2...Xl
 6
                // X1 in N
 7
                Node x1 = X1()
                res.addChild(x1)
8
9
                // X1 in N
                Node x2 = X2()
10
11
               res.addChild(x2)
                // X3 in Sigma
12
                assert x3 = token or Error()
13
                res.addChild(token)
14
15
                next()
16
17
                . . .
18
                // Xl ...
19
20
21
                return res
           FIRST'(A -> a2)
23
               . . .
24
25
           default:
26
               Error()
27 }
```

ETF (expression, therm, factor)

Grammar:

$$\begin{split} E &\rightarrow E + T \\ E &\rightarrow T \\ T &\rightarrow T \times F \\ T &\rightarrow F \\ F &\rightarrow n \\ F &\rightarrow (E) \end{split}$$

	FIRST
Е	n, (
Т	n, (
F	n, (

```
FIRST (E + T) = \{n, (\}\}
FIRST(T) = \{n, (\}\}
```

 $\operatorname{def}\Gamma$  называется *леворекурсивной*, если в  $\Gamma:A\Rightarrow^+Alpha$ 

 ${f comment}\ \Gamma$  - леворекурсивная  $\Rightarrow\ \Gamma 
otin LL(1)$ 

$$A \Rightarrow \beta \Rightarrow^* A\alpha$$

$$A \Rightarrow^* B\xi \Rightarrow \gamma\xi \Rightarrow^* A\alpha$$

$$A \Rightarrow^* B\xi \Rightarrow \delta\xi \Rightarrow^* x = cy$$

$$c \in (FIRST(\delta)) \setminus \epsilon \cup (FIRST(\xi) \text{ if } \epsilon \in FIRST(\delta))$$

$$c \in FIRST(\gamma) \setminus \epsilon \cup (FIRST(\xi) \text{ if } \epsilon \text{ in} FIRST(\gamma))$$

A o A lpha - непосредственная левая рекурсия A o eta  $eta lpha^*$ 

Устранение левой рекурсии:

$$\begin{split} A &\rightarrow \beta A' \\ A' &\rightarrow \epsilon \\ A' &\rightarrow \alpha A' \\ E &\rightarrow E + \stackrel{\alpha}{T} \\ E &\rightarrow \stackrel{\beta}{T} \end{split}$$

# Грамматика с устранённой непосредственной левой рекурсией

$$egin{aligned} E &
ightarrow TE' \ E' &
ightarrow \epsilon \ E' &
ightarrow +TE' \ T &
ightarrow FT' \ T' &
ightarrow \epsilon \ T' &
ightarrow \times FT' \ F &
ightarrow n \ F &
ightarrow (E) \end{aligned}$$

	FIRST	FOLLOW
Е	( n	\$ )
E'	+ e	\$ )
Т	( n	+ \$ )
T'	* e	+ \$ )
F	( n	* + \$ )

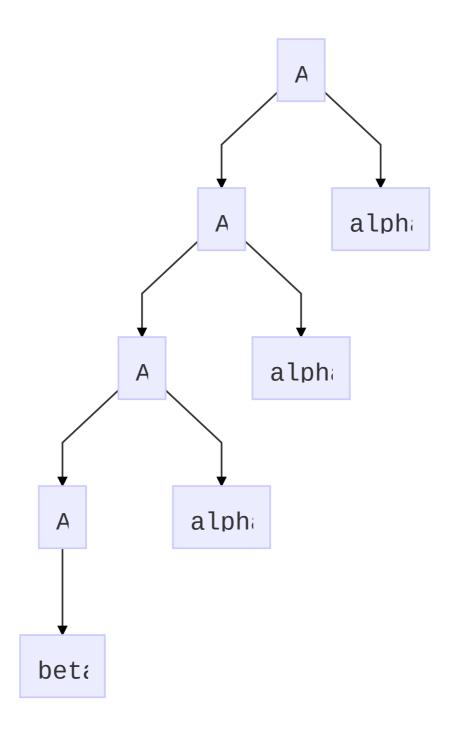
```
Node E()
 2
        Node res = Node(E)
 3
        switch (token)
            case n, (:
                // E -> TE'
                Node t = T()
 7
                res.addChild(t)
 8
                Node e' = E'()
 9
                res.addChild(e')
10
                return res
11
            default:
```

```
13
                Error()
14
15
    Node E'()
16
        Node res = Node(E')
17
        switch (token)
18
           case $, ):
               // E' -> e
19
20
               return res
21
           case +, e:
               // E' -> +TE'
22
               assert token == +
23
24
               res.addChild(Node(t))
25
               next()
26
               Node t = T()
               res.addChild(t)
27
               Node e' = E'()
28
29
               res.addChild(e')
               return res
30
31
32
           default:
33
               Error()
34
        // T and T' are similar with above
35
36
37
    Node F()
        Node res = Node(F)
38
        switch (token)
39
40
            case n:
                assert token == n
41
42
                res.addChild(n)
43
                next()
44
                return res
45
            case (:
                assert token == (
46
47
                res.addChild(\()
48
                next()
49
                Node e = E()
                res.addChild(e)
50
51
                assert token == )
52
                res.addChild(Node(\)))
53
                next()
54
                 return res
```

$$A
ightarrow Alpha \ A
ightarrow eta \ A
ightarrow eta \ A
ightarrow eta A' \ A'
ightarrow lpha A' \ A'
ightarrow \epsilon$$

```
etalpha^* A switch FIRST'(A	oeta_1)
```

$$eta_1$$
 FIRST' $(A oeta_2)$   $eta_2$  ... while (token  $\in$  FIRST' $(A o Alpha)$ )



$$A\Rightarrow^+Alpha$$
  $A o Xlpha,\ X\in \Sigma$  или  $\#X>\#A$   $A_1,A_2,\ldots,A_n,\ \#A_i=i$   $A_1 o A_1lpha$   $A_1 o eta$   $A_1 o eta A_1'$   $A_1' o lpha A_1'$   $A_1' o \epsilon$ 

1. Избавиться от  $\epsilon$ -правила

$$A_1 \rightarrow \beta A_1'$$
 $A_1 \rightarrow \beta$ 
 $A_1' \rightarrow \alpha A_1'$ 
 $A_1' \rightarrow \alpha$ 

2. 
$$A_2 o A_1lpha \leadsto A_2 o \xilpha$$
 для всех  $A_1 o \xi$   $(A_2 o A_2eta,A_2 o \gamma)$   $A_2 o A_2eta$   $A_2 o \gamma$ 

```
1  for i = 1..n
2    for j = 1..i - 1
3         A_i -> A_j alpha
4         for A_j -> xi alpha
5         add A_i -> xi alpha
6         remove A_i -> A_j alpha
```

$$egin{aligned} A & o lpha eta \ A & o lpha \gamma \ L(lpha) 
eq \{\epsilon\}, ext{ to LL(1)} \ A & o lpha A' \ A' & o eta \ A' & o \gamma \end{aligned}$$

## Построение нерекурснвных нисходящих разборов

Стек, управлящая таблица

			Σ	С		\$
N	А					
					ERROR	
Σ			SKIP			ERROR
		ERROR				

$$\begin{split} E &\rightarrow TE' \\ E' &\rightarrow \epsilon \\ E' &\rightarrow +TE' \\ T &\rightarrow FT' \\ T' &\rightarrow \epsilon \\ T' &\rightarrow \times FT' \\ F &\rightarrow n \\ F &\rightarrow (E) \end{split}$$

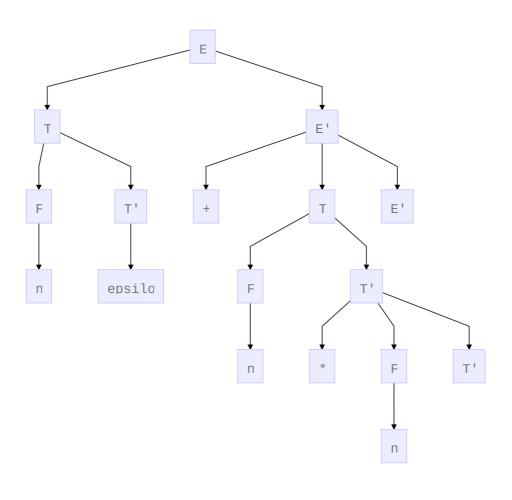
	FIRST	FOLLOW
Е	( n	\$ )
E'	+ e	\$ )
Т	( n	+ \$ )
T'	* e	+ \$ )
F	( n	* + \$ )

	n	+	*	(	)	\$
Е	1			1		
E'		2			3	3
Т	4			4		
T'		6	5		6	6
F	7			8		

пустые ячейки соответствуют ошибке

e.g. to parse: 2 + 2 \* 2

tree:



# Атрибутно-транслирующие грамматики (АТГ)

 $N,S\in N;\Sigma;P$  - правила

Расширим определние грамматики

N &  $\Sigma$  определяется в Z

#### атрибуты

 $\Sigma, N$ 

- 0. имя
- 1. тип
- 2. значение (может быть не определено)
- 3. правило вычисления S-атрибуты - только присваивание атрибута

#### Атрибуты бывают:

### 1. Синтезируемые атрибуты

Если его значение зависит только от поддерева, в том числе, когда этот атрибут - атрибут терминала и его значение на этапе лексического анализа

### 2. Наследуемый атрибут

Значение зависит от родителей или братьев L-атрибутная **Транслирующий символ** - специальный нетерминал, у которого единственное правило раскрыть его в  $\epsilon$  и которого есть связанный с ним код, внутри которого мы можем работать с атрибутами

### Могут быть именными и анонимными

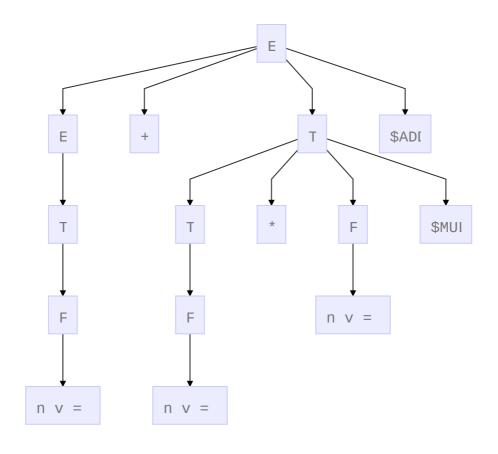
E  o E + T	\$MUL op1 = $T_1.v$ \$MUL op2 = $F.v$ $T_0.v$ = \$MUL res
E o T	E.V = T.V
$T_0  ightarrow T_1 \hspace{0.1cm} imes_2 \hspace{0.1cm} F_3$	$MUL op1 = T_1.v$ MUL op2 = F.v $T_0.v = MUL res$
T  o F	T.v = F.v
F o n	F.V = n.V
F o(E)	F.V = E.V

```
1 | $MUL {
2 | res = op1 * op2
3 | }
```

$$\$MUL \left\{ egin{array}{l} op1$$
 наследуемый  $op2$  наследуемый  $res$  синтезируемый

```
1 | $ADD {
2 | add = op1 + op2
3 | }
```

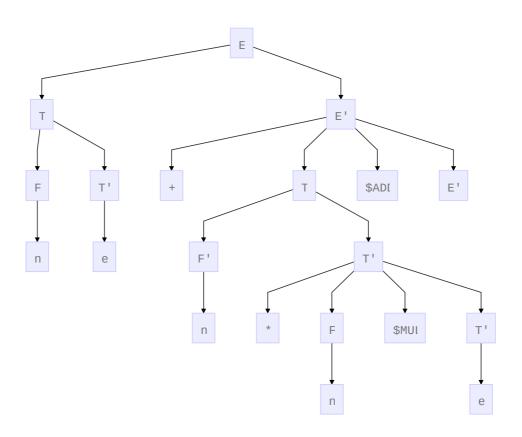
Е	V	
Т	V	
F		синтезируемый
n		синтезируемый



E  o TE'		E'.a = T.v E.v = E'.v
E'  ightarrow + TE'	\$ADD E'	$ADD op1 = E'_0a$ ADD op2 = T.v $E'_4.a = ADD.res$
$E'  o \epsilon$		E'.v = E'.a
T  o FT'		T'.a = E'.a T.v = T'.v
T'  o  imes FT'	\$MUL T'	\$MUL op1 = $T'_0.a$ \$MUL op2 = F.v $T'_4.a$ = \$MUL res
$T'  ightarrow \epsilon$		T'.v = T'.a
F o n		F.v = n.v
F o(E)		F.v = E.v

Е	v
Т	V
F	v синтезируемый
n	v синтезируемый
E'	а наследуемый v синтезируемый
T'	а наследуемый v синтезируемый

### 2 + 3 \* 4



```
E'(a: int): int
2
        switch
3
            case // -> e
4
                return a
            case // +T $ADD E'
 5
                skip +
 6
7
                T.v = T()
                ADD.res = ADD(a, T.v)
8
                E'.v = E'($ADD.res)
 9
                return E'.v
10
```

```
11
12
   E(): int
    switch
13
14
      case
15
             T.v = T()
            E'v. = E'(T.v)
16
17
             return E'.v
18
19
   $ADD(op1, op2: int): int
20
      return op1 + op2
21
22 // alternative:
   Node E'(a)
23
24
      Node res = Node(E, atr = \{a.a\})
25
26
      switch
27
        -> e
28
            res v = res.a
29
            return res
         -> +TE'
31
            skip +
32
            T = T()
33
            E'4.a = res.a + T.v
34
            E' = E'(E'4.a)
35
            res.v = E'v
36
             return res
```

### Регистровые машины и Стековые машины

операции регистровых машин: load загрузить значение и store выгрузить в память преимущество перед регистровыми, в регистровых конечное количество регистров, здесь есть стек и операции push, pop

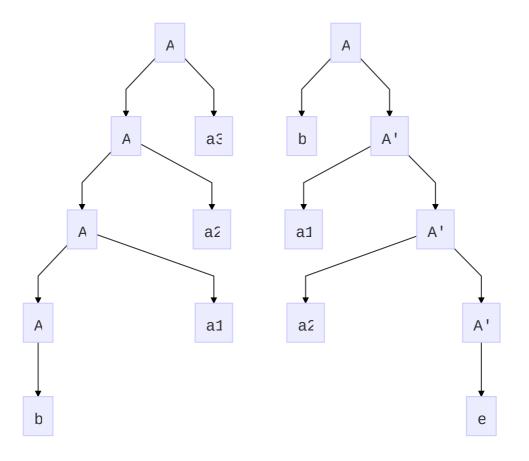
Непосредственная левая рекурсия

```
A 	o A \alpha
```

х - синтезируемый атрибут А

$$A o \beta A'$$

$$A' o \epsilon$$



А' х - соответствует Ах - синтезируемый

а - аккумулятор - наследуемый

$$egin{aligned} A &
ightarrow eta A' & A'a = f(eta) \ A' &
ightarrow \epsilon \ A' &
ightarrow lpha A' \end{aligned}$$

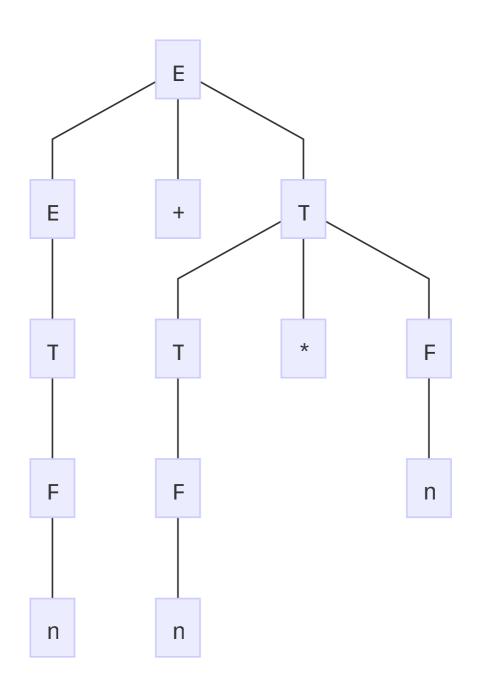
A s - синтезируемый атрибут

а - наследуемый атрибут

```
1 A(a) -> s
2 switch ()
3 ....
4 // A -> a
5 s = f(alpha)
6 // alpha_k = B
7 B(<->)
```

Но вообще генерируются парсеры со стеком

# Восходящий разбор



#### LR - анализ

LR(0) редко используется, есть LR(1)  $LR \rightarrow SLR$  (Simple LR) ->  $LALR \rightarrow LR(1)$ 

$$\eta Bu \Rightarrow \eta \beta u = \xi At \Rightarrow \xi \alpha t = \omega$$

$$\gamma = \xi t \hspace{0.5cm} S \Rightarrow^* \gamma \hspace{0.5cm} \xi \in (\Sigma \cup N)^*, t \in \Sigma^*$$

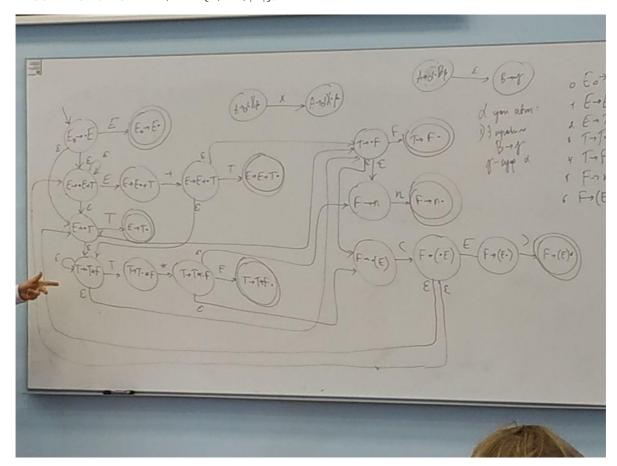
lpha - подстрока  $\gamma$ 

 $\gamma = \xi' \alpha t' \quad \xi'$  - подстрока  $\xi$ , t' - суффикс t

$$S \Rightarrow^* \xi' A t' \Rightarrow \xi' \alpha t' = \xi t$$

Ситуации (items)

LR(1) - ситуация ( $A 
ightarrow lpha, K \in \{0, \ldots, |lpha|\}$ )




# Теорема

Ели строка альфа допускается автоматом, построенным по этим правилам, то:

1. Существует правио  $B o \gamma$ ,  $\gamma$  - суффикс  $\alpha$ 

9									
	IE	T	F	(	)	n	+	*	
[E0+1][E+E+][E+T][F+T][F+T][F+F][F+(E)][F+B)	2	3	4	5		6			
[E,-E-)[E-E-17]							7		
3 [E-T-] (T-T- OF)								8	
Y(T→ f·)									
5 [F+(+E)][F+F+][F+T)[F+T+F)[F++[F][F++(E)][F+++]	9	2	4	5		6			-
6 (F-n.)		-		9		0			
+ (E+E+1)(T++7)(F+F)(F+(E))(F+++)		10	4	-					
8 (1-str.f) (F- (E)] (F-1)				5		6			
5[F+(E)][E+E++7]			1	5		6			
(E+E+T) [F+T-XF]					12		7		
1 [[-7]xf.]								8	
								9	
[2(E~(E)·)									




	IE	T	n	+
amapm )[E = . E][E E + T](E - T)(T n)	2	3	4	
2)[EE.][E-E.+T]				5
3)(€→Т-)				
4) [I-n.]				
5) [E > E+.T] [T-1.n]		6	4	
(E > E+T.) () [E > E+T.)				-

**def** Грамматика называется *LR0 грамматикой*, если детерминированная версия автомата по поиску основы каждое состояние содержит либо одно состояние недетерминированного автомата и ничего больше, либо содержит только нетерминальные состояния недетермнированного автомата.

Конфликт свёртки/свёртки ноль нетерминальных и больше одного терминала Конфликт переноса/свёртки: больше нуля нетерминальных и больше нуля терминальных

Когда не работает SLR:



### LR1

**def** *LR1-ситуация* - это тройка из правила, числа от 0 до длины правой части и символа, который называется \*символом предпросмотра (look ahead)

$$egin{aligned} [A 
ightarrow lpha ullet eta, c] \ [A 
ightarrow lpha ullet d eta, c] & \stackrel{d}{
ightarrow} [A 
ightarrow lpha a ullet eta, c] \end{aligned}$$

lr1 - грамматике - если в детерминированном автомате по поиску lr1 основ

одно из них терминальное, а другое нетерминальное, то их символ предпросмотра отличается от символа перед которым находится позиция в правой части нетерминального

если они оба терминальные, то их символ предпросмотра не совпадает

lr1 приколюхи